LABORATORIO DE APRENDIZAJE ESTADÍSTICO

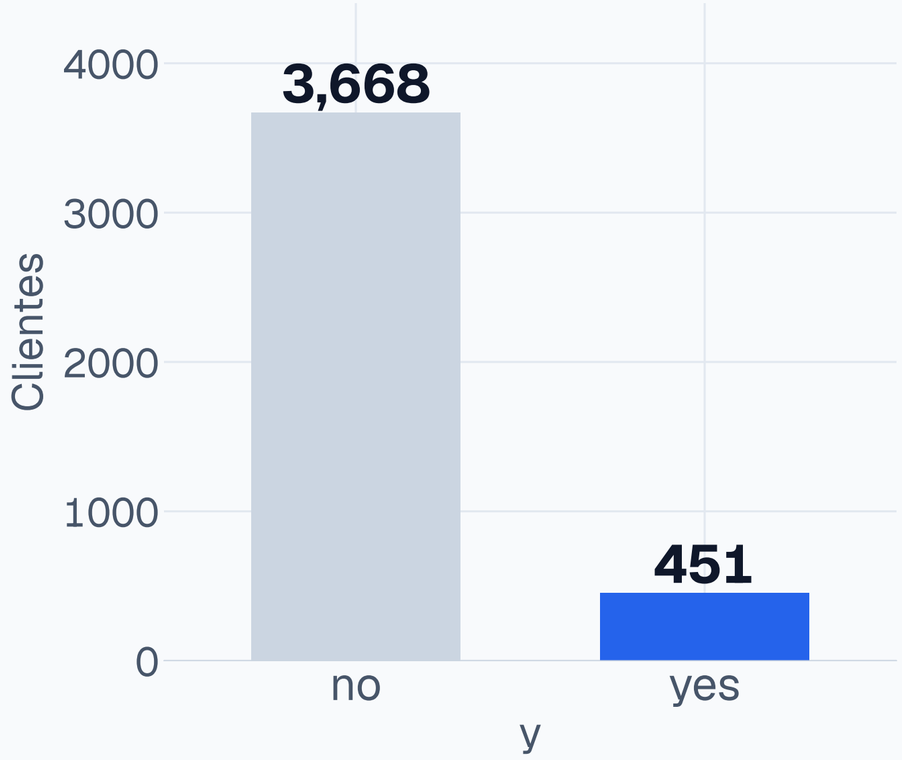
¿A quién llamar para vender un depósito a plazo?

Cecilia Quiroz Hidalgo

Abraham Casarrubias Rosales

Carlos Enrique Nieves Ochoa

Solo 11 de cada 100 clientes contratan el depósito



Llamar a todos cuesta tiempo y casi siempre se recibe un no.

Un modelo que diga no a todos acierta 89% sin encontrar a nadie.

Usamos el AUC, que mide qué tan bien ordena a los clientes de más a menos probable.

Variable objetivo y, donde yes significa que contrató, 451 de 4,119 clientes

02 · LOS DATOS

Usamos 4,119 llamadas de un banco portugués entre 2008 y 2010

Cliente

7

edad, empleo, escolaridad, créditos

Último contacto

4

medio, mes, día y duración

Historial

4

llamadas previas y su resultado

Economía

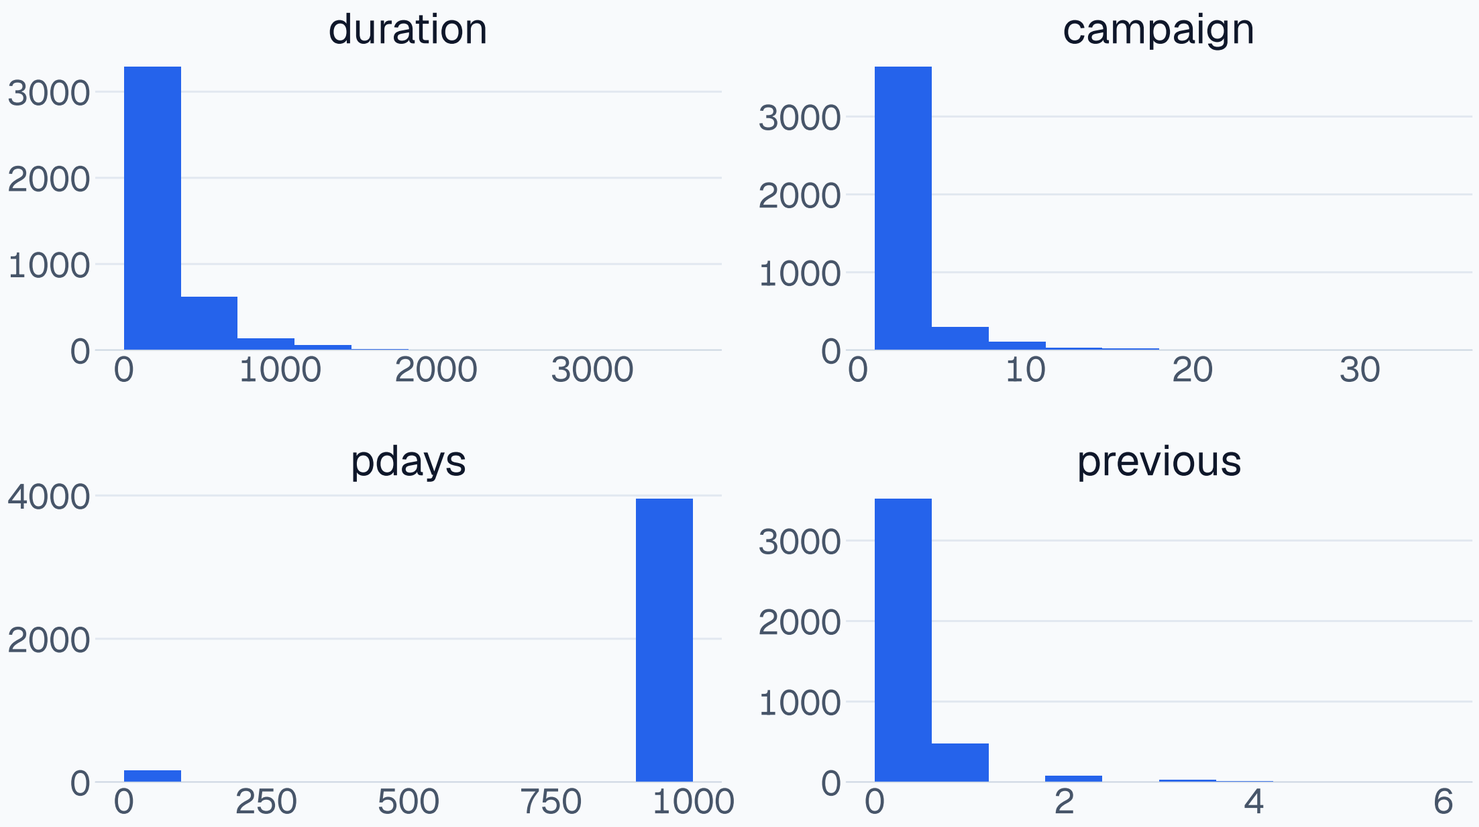
5

Euribor, empleo, precios, confianza

La respuesta es si el cliente contrató. No hay nulos, aunque varios faltantes vienen como "unknown".

Fuente: Moro, Rita y Cortez (2014), UCI Machine Learning Repository, muestra del 10%

Los histogramas muestran variables muy cargadas a un lado



Cada barra cuenta cuántos clientes caen en ese rango de valores.

En pdays casi todos valen 999, y en campaign y duration hay pocos valores muy altos.

Cuatro de las diez variables numéricas del notebook

Quitamos duration porque solo se conoce al colgar

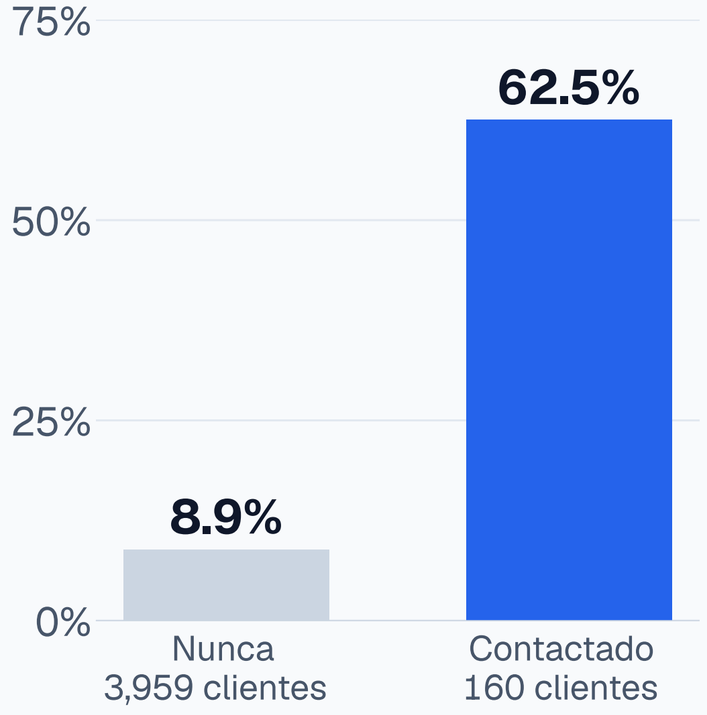
Variable	Problema	Qué hicimos
`duration`	Se sabe hasta terminar la llamada	La eliminamos
`pdays`	999 significa nunca contactado (96.1%)	Binaria de contacto previo
`default`	Solo un cliente dice que sí	Binaria de "no se sabe"
`campaign`	Muy sesgada, mediana 2 y máximo 35	Logaritmo de 1 + x
Categóricas	Son texto y los modelos usan números	OneHotEncoder

Tras quitar 19 duplicados quedan 4,100 clientes.

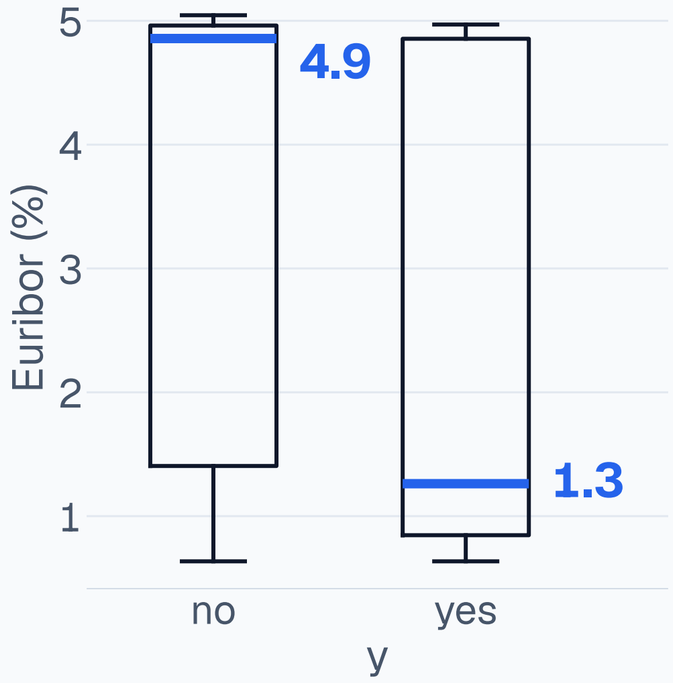
También juntamos illiterate, con un solo registro, con basic.4y

El contacto previo y las tasas bajas van con más contratación

Contrataron según contacto previo



Euribor a 3 meses por respuesta



La línea azul es la mediana y la caja guarda la mitad central de los clientes.

Quienes contrataron estaban en tasas más bajas, con mediana de 1.3 frente a 4.9.

Son asociaciones, no prueban que la tasa cause la contratación

04 · EL PROCESO

Preparamos los datos dentro del pipeline para no filtrar información

01 · PREPARAR

Limpiar y transformar variables

02 · SEPARAR

70% para entrenar y 30% para prueba

03 · AJUSTAR

Escalar, codificar y entrenar en cada fold

04 · EVALUAR

Una sola vez con los datos de prueba

K-Fold parte el entrenamiento en 10 grupos, llamados folds, y cada uno valida una vez.

Entrenamiento de 2,870 clientes y prueba de 1,230 clientes

Comparamos tres modelos y buscamos sus hiperparámetros

Regresión logística

Frontera lineal con regularización L2

C 10^{-6} a 10^{2}

SVM con kernel RBF

Frontera que puede ser curva

C 10^{-2} a 10^{3}
γ 10^{-6} a 10^{0}

Perceptrón multicapa

Red neuronal con una capa oculta

neuronas 2 a 128
α 10^{-5} a 10^{2}

C y α controlan la regularización, que castiga los modelos muy complejos, y γ qué tan curva es la frontera

Con 20 evaluaciones evitamos probar toda la malla

20 bayesiana

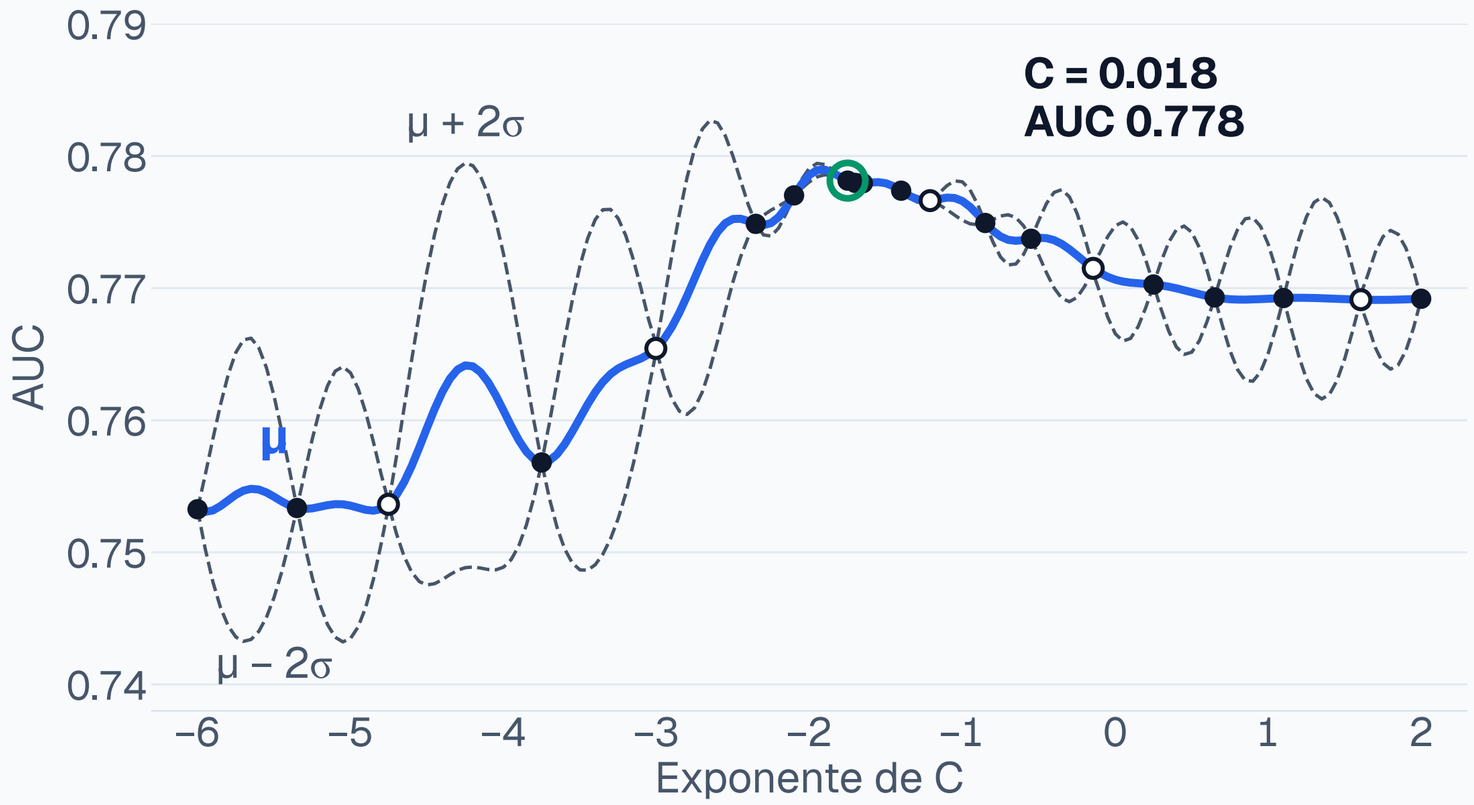
806 malla de la SVM

$$x_{\text{siguiente}} = \arg\max_{x} \left[\mu(x) + 2\,\sigma(x) \right]$$

Un proceso gaussiano estima el AUC (μ) y su duda (σ). Tras 5 puntos al azar, probamos donde μ + 2σ es mayor.

Rasmussen y Williams (2006)

Una regularización intermedia da el mejor AUC en la logística

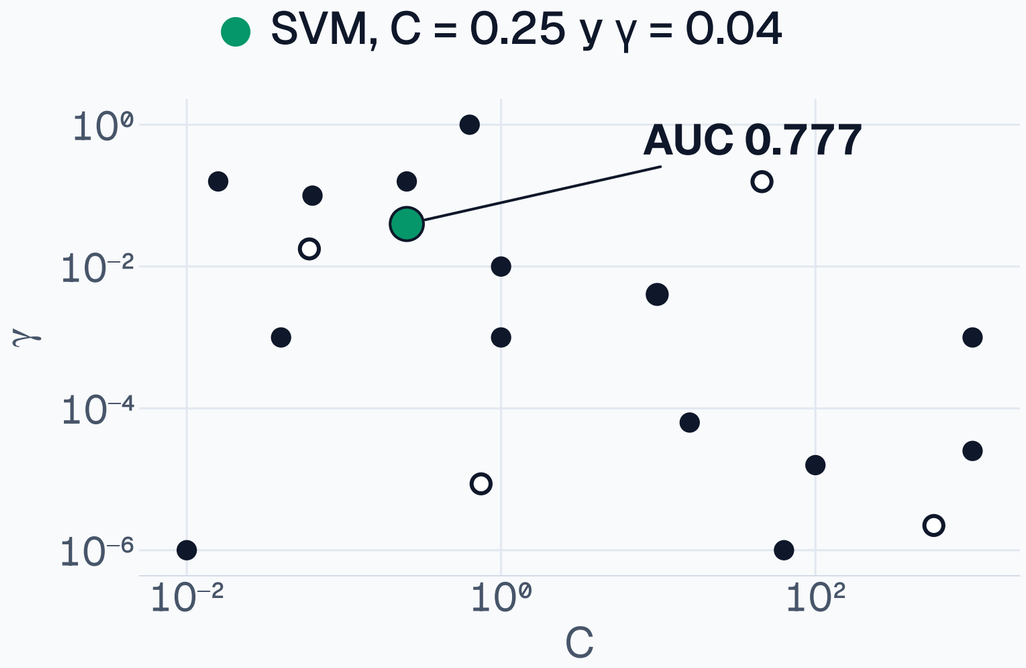


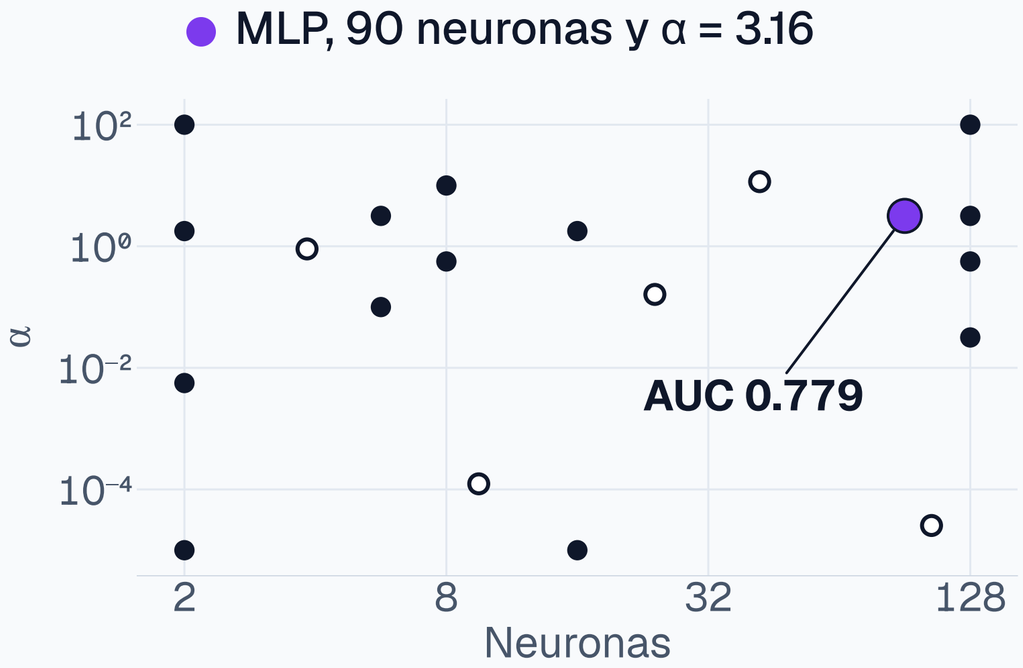
Las punteadas marcan la duda del proceso gaussiano y se abren donde evaluamos poco.

El máximo está en C = 0.018, y con regularización excesiva el AUC baja a 0.753.

Blancos, los 5 puntos al azar. Negros, los 15 que eligió el proceso gaussiano. Un C chico regulariza más

La SVM y el MLP encuentran su mejor punto dentro del rango

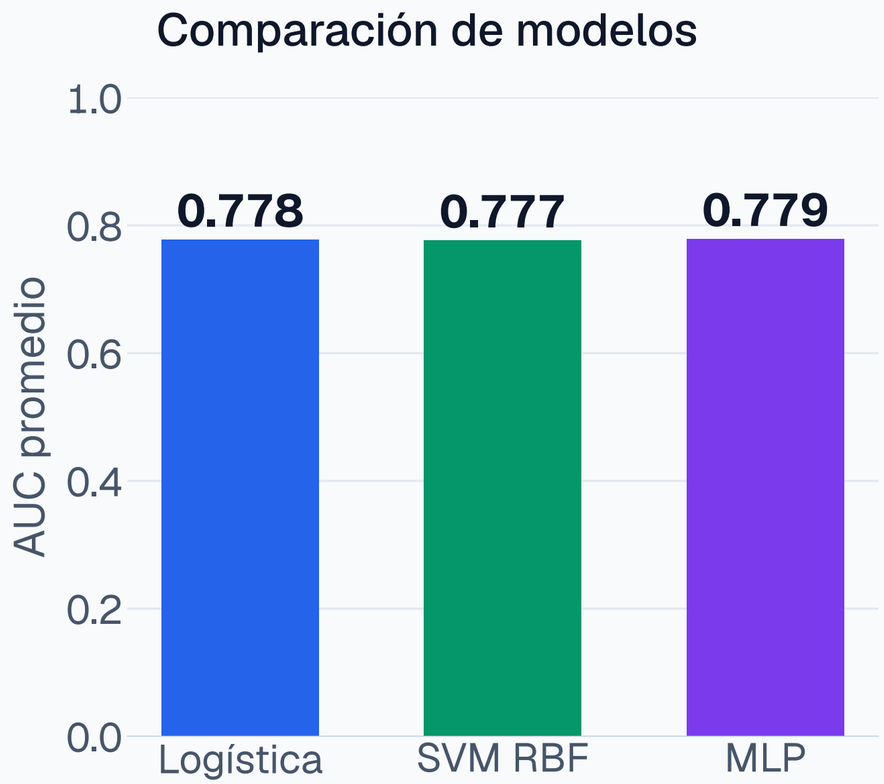


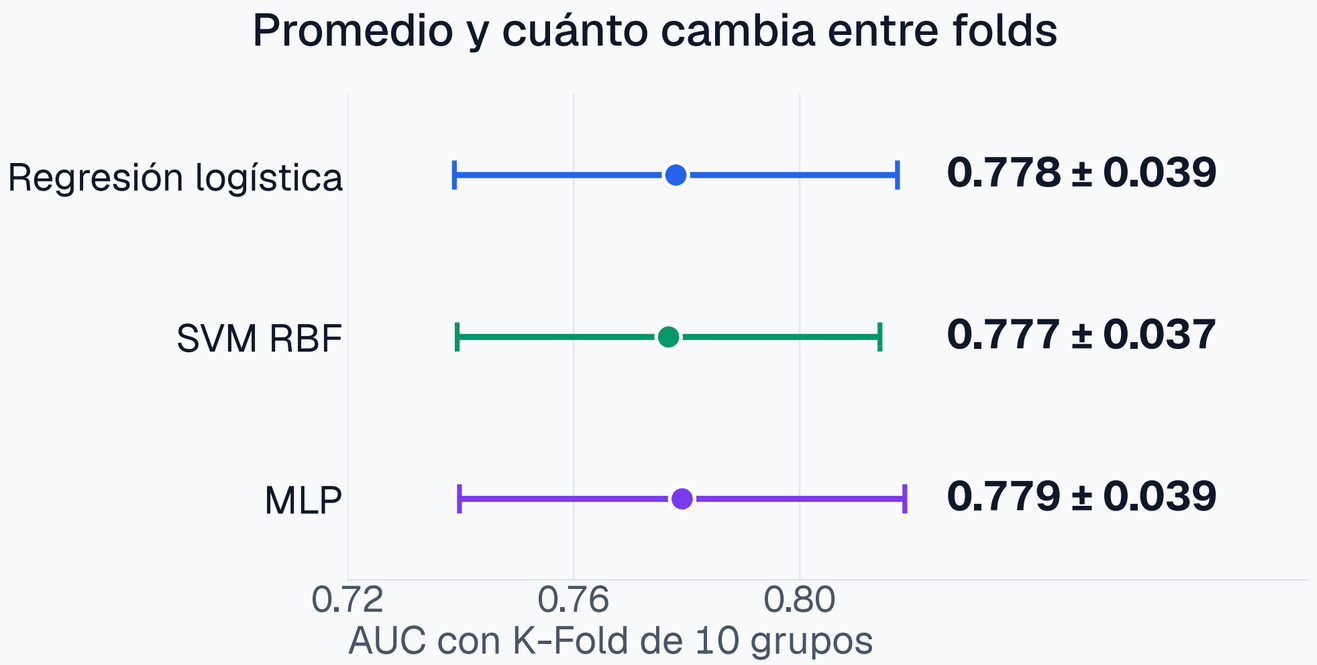


> El mejor punto de color no toca el borde, así que el rango que elegimos alcanzó.

Cada punto es una evaluación del AUC, 20 por modelo. En la SVM, Optuna con TPE llegó a 0.774 frente a 0.777

Los tres modelos empatan en K-Fold





Entre modelos hay 0.002 de diferencia y cada uno cambia cerca de 0.04 de un fold a otro.

Línea, una desviación estándar. Un AUC de 0.5 equivale al azar. En prueba también empatan, con 0.765, 0.760 y 0.760

La regresión logística encuentra 83 de los 142 que contratan



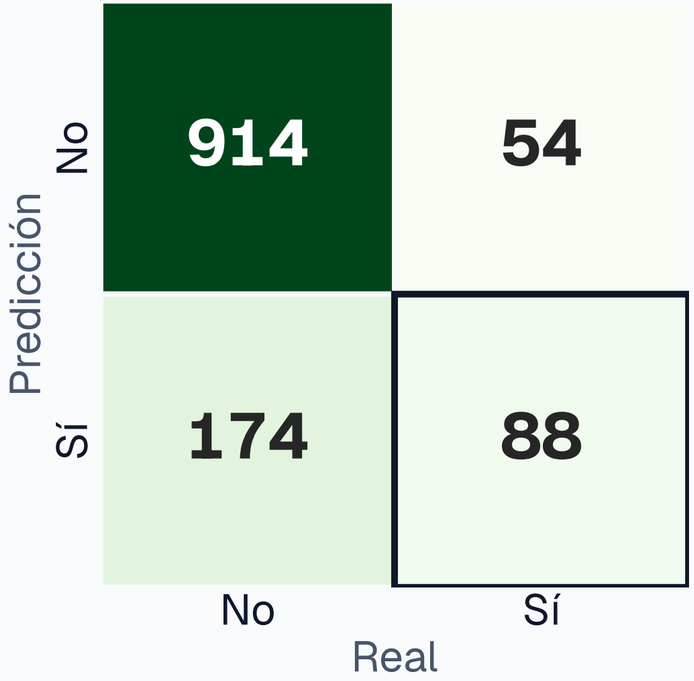
El recall es la parte de los que contratan que el modelo encuentra, aquí 58.5%.

La precisión es la parte de las llamadas que termina en sí, aquí 35.8%.

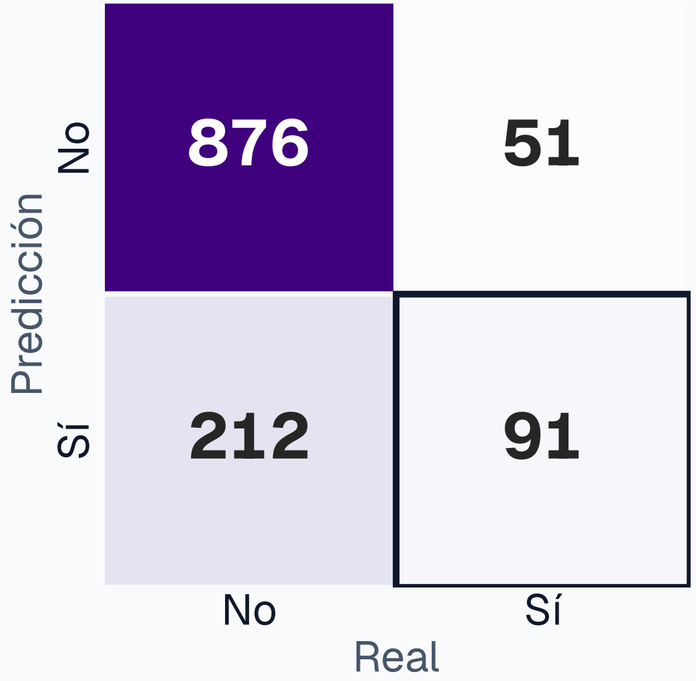
Prueba de 1,230 clientes con umbral de 0.5. Las columnas son lo real y las filas lo que predice el modelo

Los otros dos encuentran 5 y 8 ventas más, con 30 y 71 llamadas más

SVM con umbral de 0.1



MLP con umbral de 0.1

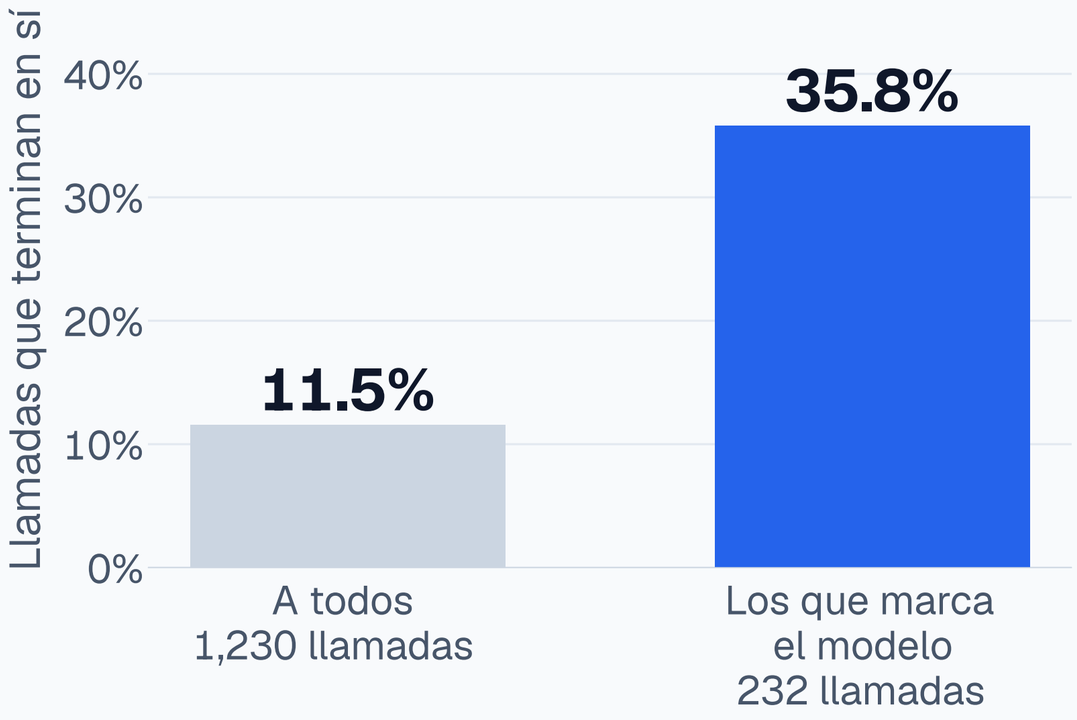


La fila Sí suma las llamadas de cada modelo, 262 y 303 contra 232.

Comparamos con un recall parecido porque el peso de clases cambia las probabilidades.

Umbrales elegidos viendo la prueba. El recuadro marca las ventas encontradas

Llamar a quien marca el modelo triplica la tasa de éxito



Con 19% de las llamadas alcanzamos 58.5% de los que contratan.

Elegimos la regresión logística porque empata y es la más simple.

Separamos al azar, así que una campaña futura podría rendir menos.