LABORATORIO DE APRENDIZAJE ESTADÍSTICO

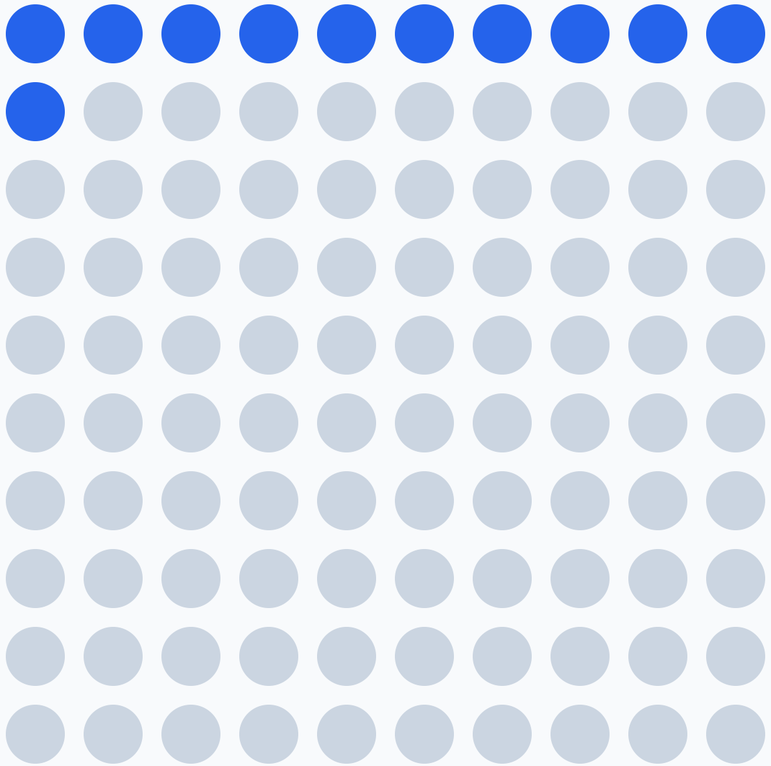
¿A quién llamar para vender un depósito a plazo?

Cecilia Quiroz Hidalgo

Abraham Casarrubias Rosales

Carlos Enrique Nieves Ochoa

Solo 11 de cada 100 clientes contratan el depósito



Cada punto es un cliente y los azules contrataron. En los datos son 451 de 4,119.

Llamar a todos cuesta tiempo y casi siempre se recibe un no.

Un modelo que diga no a todos acierta 89% sin encontrar a nadie.

Usamos el AUC, que mide qué tan bien ordena a los clientes de más a menos probable.

02 · LOS DATOS

Usamos 4,119 llamadas de un banco portugués entre 2008 y 2010

Cliente

7

edad, empleo, escolaridad, créditos

Último contacto

4

medio, mes, día y duración

Historial

4

llamadas previas y su resultado

Economía

5

Euribor, empleo, precios, confianza

La respuesta es si el cliente contrató. No hay nulos, aunque varios faltantes vienen como "unknown".

Fuente: Moro, Rita y Cortez (2014), UCI Machine Learning Repository, muestra del 10%

Quitamos duration porque solo se conoce al colgar

Variable	Problema	Qué hicimos
`duration`	Se sabe hasta terminar la llamada	La eliminamos
`pdays`	999 significa nunca contactado (96.1%)	Binaria de contacto previo
`default`	Solo un cliente dice que sí	Binaria de "no se sabe"
`campaign`	Muy sesgada, mediana 2 y máximo 35	Logaritmo de 1 + x
Categóricas	Son texto y los modelos usan números	OneHotEncoder

Tras quitar 19 duplicados quedan 4,100 clientes.

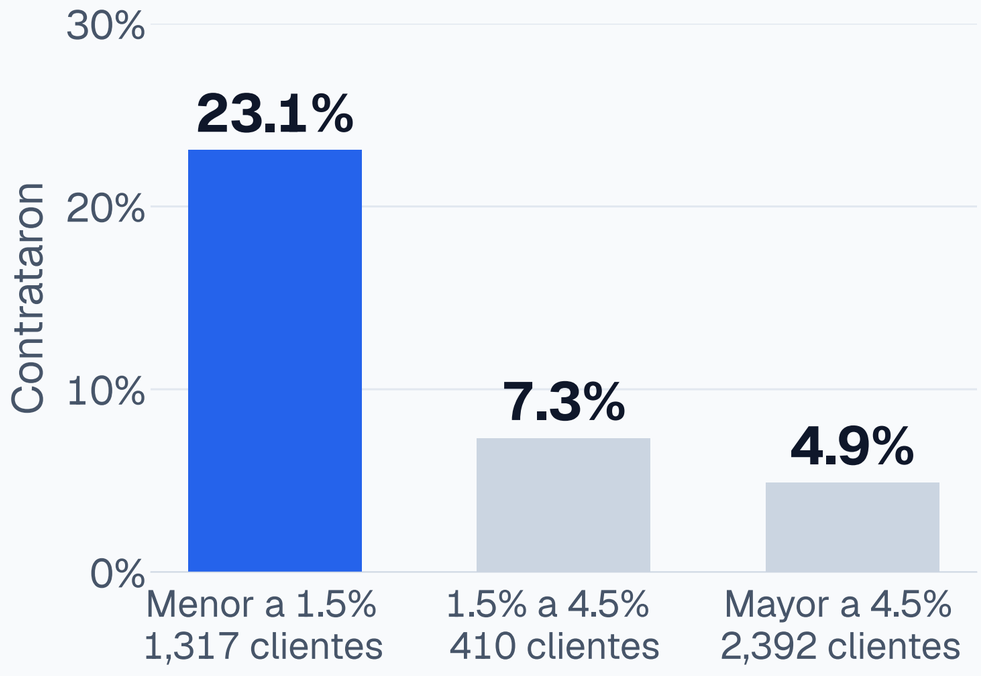
También juntamos illiterate, con un solo registro, con basic.4y

El contacto previo y las tasas bajas van con más contratación

Según el contacto previo



Según la Euribor a 3 meses



Son asociaciones, no prueban que la tasa cause la contratación

04 · EL PROCESO

Preparamos los datos dentro del pipeline para no filtrar información

01 · PREPARAR

Limpiar y transformar variables

02 · SEPARAR

70% para entrenar y 30% para prueba

03 · AJUSTAR

Escalar, codificar y entrenar en cada fold

04 · EVALUAR

Una sola vez con los datos de prueba

K-Fold parte el entrenamiento en 10 grupos, llamados folds, y cada uno valida una vez.

Entrenamiento de 2,870 clientes y prueba de 1,230 clientes

Comparamos tres modelos y buscamos sus hiperparámetros

Regresión logística

Frontera lineal con regularización L2

C 10^{-6} a 10^{2}

SVM con kernel RBF

Frontera que puede ser curva

C 10^{-2} a 10^{3}
γ 10^{-6} a 10^{0}

Perceptrón multicapa

Red neuronal con una capa oculta

neuronas 2 a 128
α 10^{-5} a 10^{2}

C y α controlan la regularización, que castiga los modelos muy complejos, y γ qué tan curva es la frontera

Con 20 evaluaciones evitamos probar toda la malla

20 bayesiana

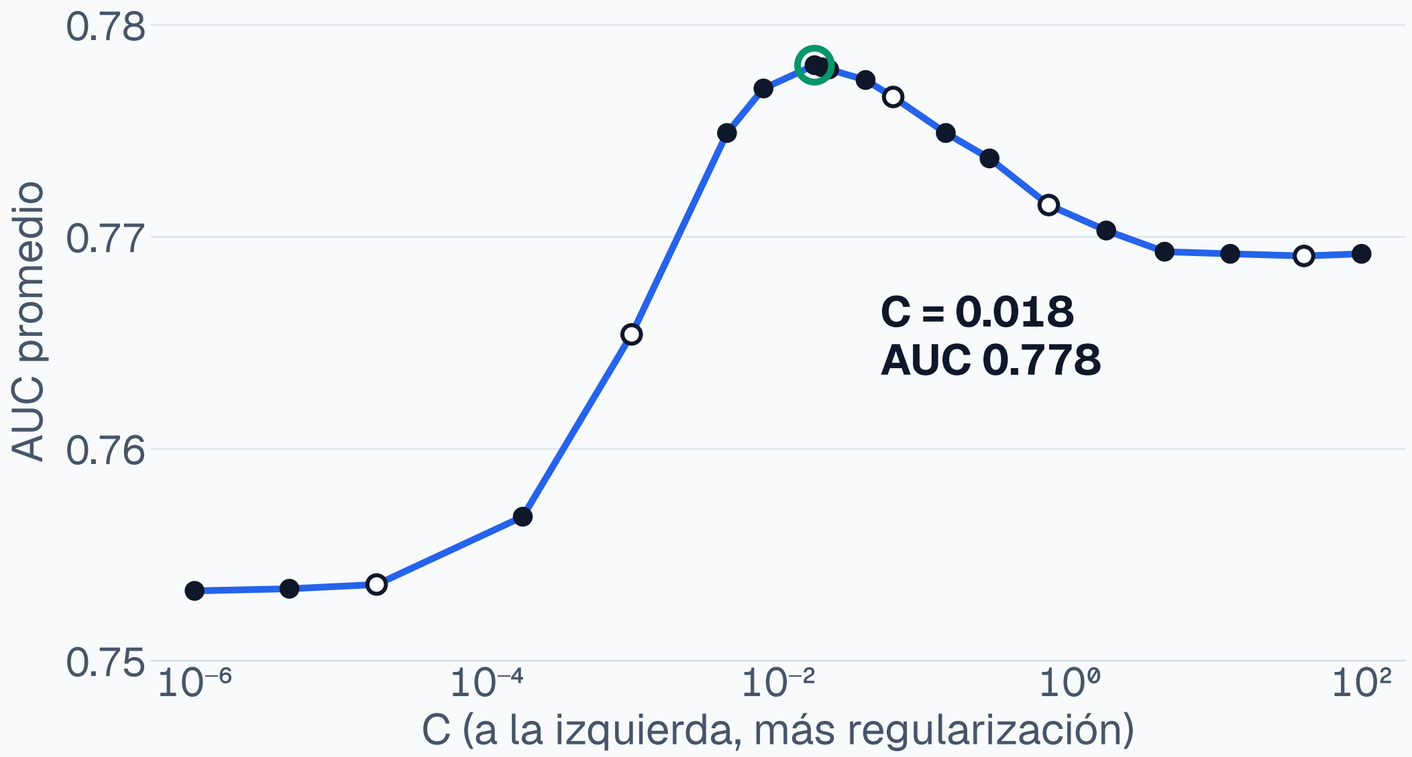
806 malla de la SVM

$$x_{\text{siguiente}} = \arg\max_{x} \left[\mu(x) + 2\,\sigma(x) \right]$$

Un proceso gaussiano estima el AUC (μ) y su duda (σ). Tras 5 puntos al azar, probamos donde μ + 2σ es mayor.

Rasmussen y Williams (2006)

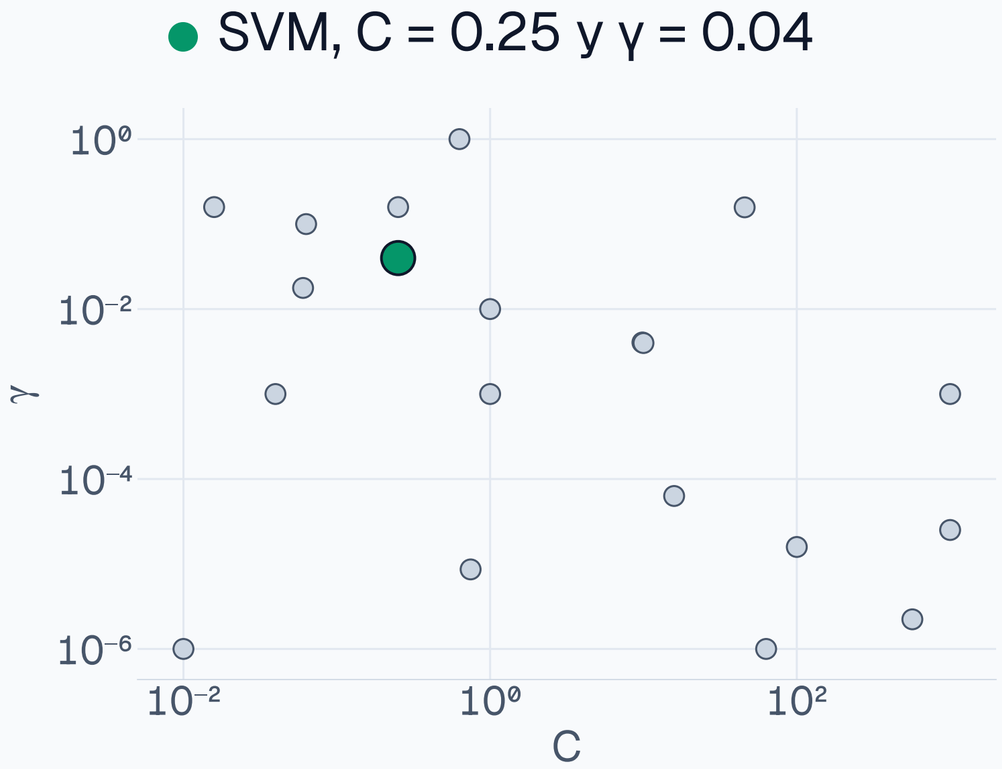
Una regularización intermedia da el mejor AUC en la logística

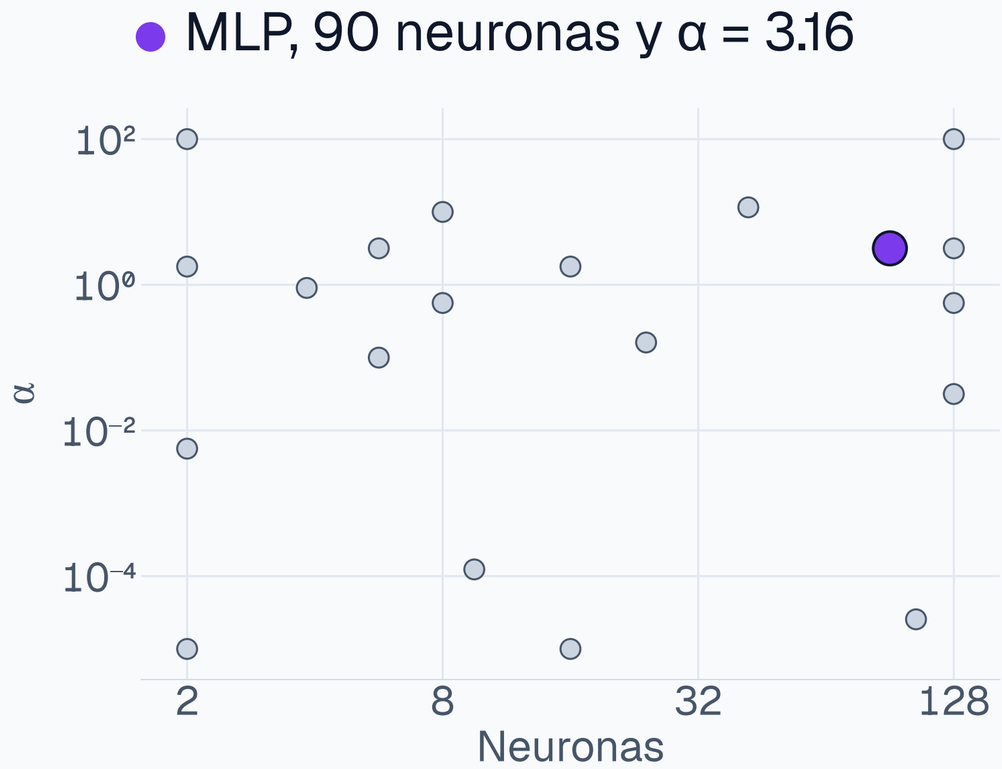


Los círculos blancos son los 5 puntos al azar y los negros, los que eligió el proceso gaussiano.

Casi sin regularizar el AUC baja poco, pero con demasiada baja más.

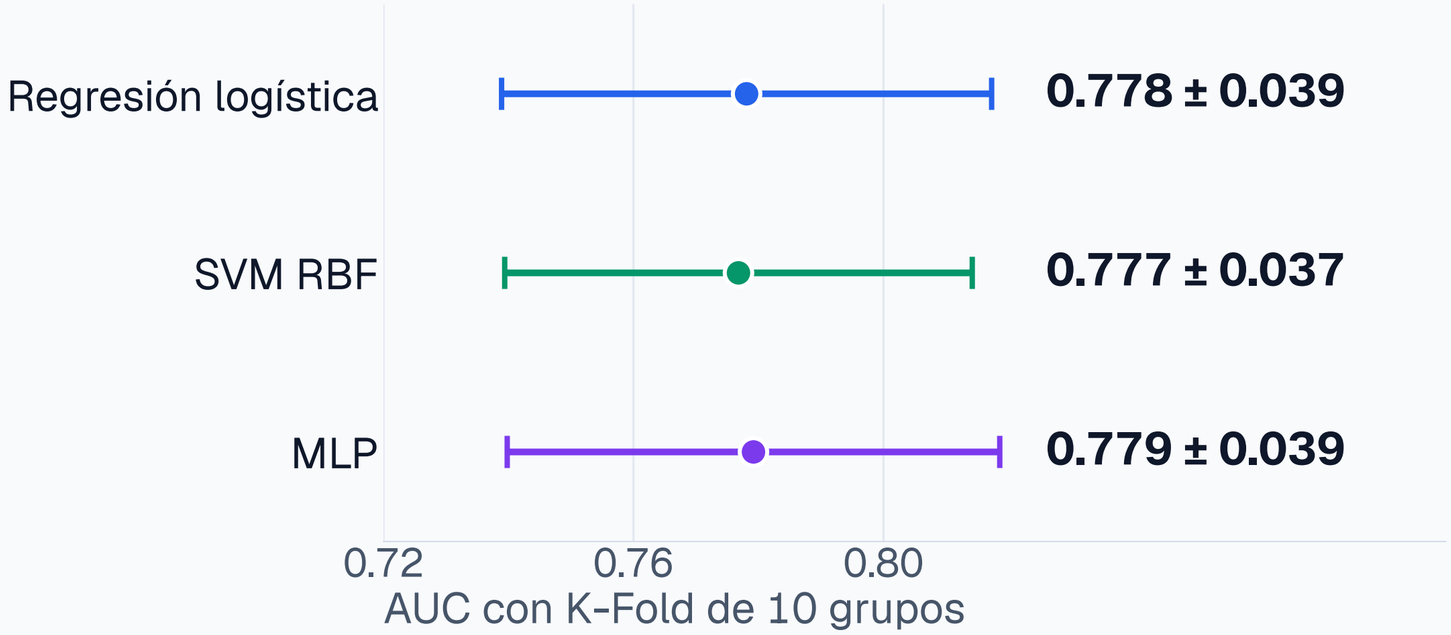
La SVM y el MLP encuentran su mejor punto dentro del rango





Cada punto es una evaluación y el de color es la mejor. En la SVM, Optuna con TPE llegó a 0.774 frente a 0.777

Los tres modelos empatan en K-Fold



La diferencia entre modelos es mucho menor que lo que cambia cada uno de un fold a otro.

En prueba tampoco se separan, con 0.765, 0.760 y 0.760.

Punto, media del AUC. Línea, una desviación estándar. Un AUC de 0.5 equivale al azar

La regresión logística encuentra 83 de los 142 que contratan

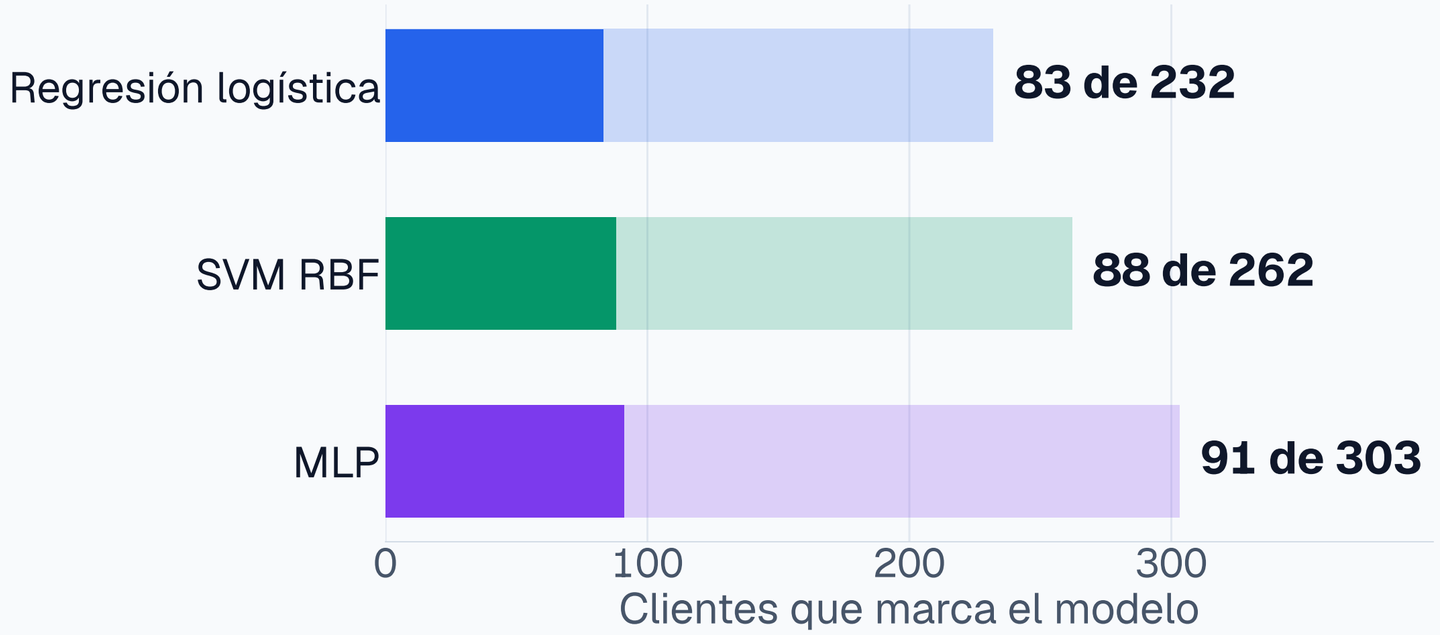
	Predice no	Predice sí
Real no	**939** No contrata y no lo llamamos	**149** Llamada de más
Real sí	**59** Cliente que se escapa	**83** Venta encontrada

El recall es la parte de los que contratan que el modelo encuentra, aquí 58.5%.

La precisión es la parte de las llamadas que termina en sí, aquí 35.8%.

Prueba de 1,230 clientes con umbral de 0.5

Los otros dos encuentran 5 y 8 ventas más, con 30 y 71 llamadas más



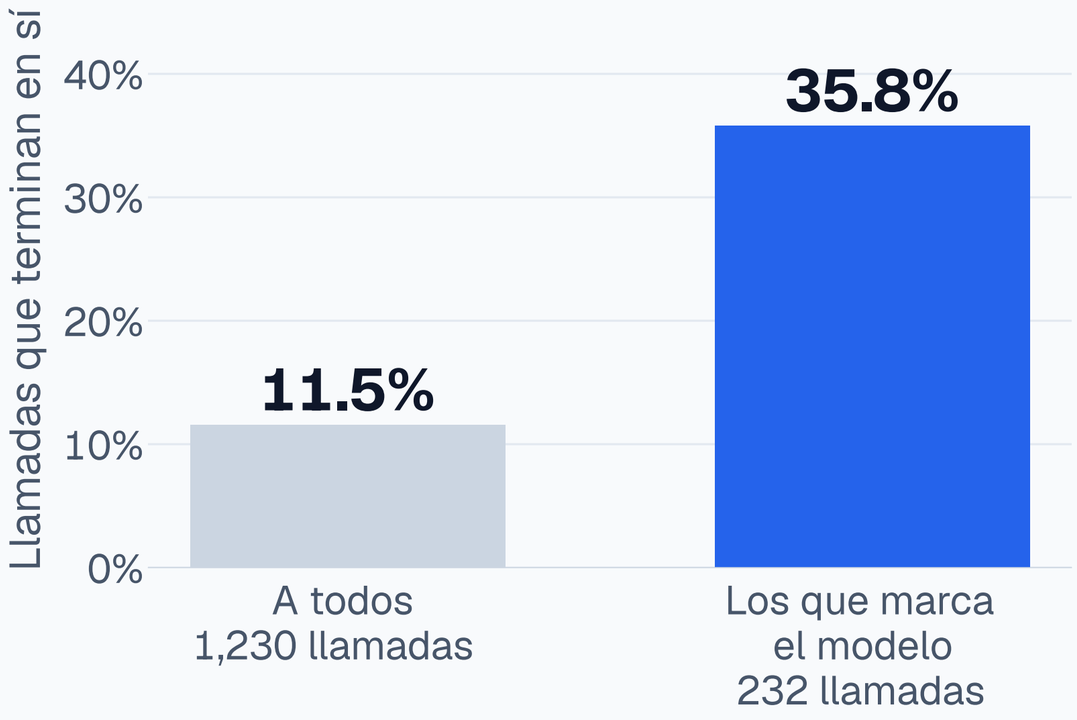
La parte de color de cada barra son los clientes que sí contratan.

Comparamos con un recall parecido porque el peso de clases cambia las probabilidades.

Umbral de 0.5 en la regresión logística y de 0.1 en SVM y MLP, elegidos viendo la prueba

07 · CONCLUSIÓN

Llamar a quien marca el modelo triplica la tasa de éxito



Con 19% de las llamadas alcanzamos 58.5% de los que contratan.

Elegimos la regresión logística porque empata y es la más simple.

Separamos al azar, así que una campaña futura podría rendir menos.